

Министерство образования Республики Беларусь

Учреждение образования
«БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ»

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

Лабораторная работа №4

по дисциплине «Естественно-языковой интерфейс интеллектуальных
систем»

на тему «Автоматический машинный перевод текстов
(вариант 11)»

Выполнили студенты гр. 321701

Ковальчук В. Н.
Самович В. М.

Проверил

Крапивин Ю. Б.

Минск 2026

Цель: освоить на практике основные принципы машинного перевода документов.

Задание (вариант 11): разработать систему автоматического машинного перевода текстов со следующей комбинацией признаков варианта:

- **Направление перевода** – англо-французский;
- **Предметная область** – научные статьи по медицине, критика предметов изобразительного искусства.

Система должна:

- на входе принимать естественно-языковой текст на входном языке, подлежащий машинному переводу;
- подсчитывать количество слов во входном тексте, количество слов в переводе и долю слов, для которых перевод найден в словаре, а также определять грамматическую информацию (теги частей речи – с использованием функциональности ЛР3 весеннего семестра, POS-теги, выводятся как есть, без перевода на русский язык);
- на выходе выдавать:
 - а) перевод входного текста на выходной язык;
 - б) упорядоченный по частоте встречаемости в тексте список слов и их переводов на выходной язык с грамматической информацией (*вкладка 1*, с использованием функциональности ЛР1 весеннего семестра – частотный список слов);
 - в) построенное дерево синтаксического разбора выбранного предложения (*вкладка 2*);
- обеспечивать наличие утилиты автоматического пополнения/корректировки полученного словаря (таблицы БД);
- обеспечивать сохранение и распечатку результатов перевода и упорядоченных по частоте встречаемости в тексте списков слов и их переводов на выходной язык с грамматической информацией в файл формата txt кодировки Unicode;
- иметь простой и доступный пользовательский интерфейс с понятным набором инструментов.

Среди трёх основных типов систем машинного перевода – систем прямого перевода, систем непрямого перевода (с трансфером или языком-посредником) и систем, основанных на знаниях – по варианту для реализации выбрана **система прямого (пословного) перевода**: исходный текст токенизируется, каждое слово ищется в двуязычном словаре по паре (лемма, часть речи) и заменяется на переводной эквивалент; переводная модель как таковая не используется, учитывается лишь локальный контекст (грамматическая форма слова через POS-тег). Сверх обязательного по варианту дополнительно реализованы ещё два типа – не прямой перевод с трансфером

и нейросетевой перевод предобученной моделью – для практического сравнения всех трёх на одной тестовой коллекции (см. раздел «Трансферный и нейросетевой методы» далее).

Структура разработанной системы

Машинный перевод реализован как новый сценарий использования поверх архитектуры ЛР1–ЛР3 (см. `docs/ARCHITECTURE.md`): границы сервисов по-прежнему проведены по зоне ответственности, а не по лабораторной работе. Для прямого и трансферного методов перевода (см. далее) отдельный микросервис не понадобился, в отличие от ЛР2 (`lang-id-service`) и ЛР3 (`summarization-service`) – перевод по словарю и синтаксический разбор предложения являются такими же операциями «текст на входе – разбор `sraCy` – чистый результат на выходе», как токенизация и лемматизация, поэтому они естественно легли в уже существующий `nlp-service`, а хранение словаря и истории переводов – в уже существующий `api`. Нейросетевой метод – исключение: локальная модель тянет за собой тяжёлую ML-зависимость (`transformers/PyTorch`) и отдельно скачиваемые веса, поэтому выделена в новый `mt-service`, по тому же принципу изоляции тяжёлых зависимостей, что и `lang-id-service`. Структура системы на уровне контейнеров (С4, уровень 2) показана на рисунке 1; связи, добавленные именно в этой лабораторной работе, выделены зелёным цветом.




Рисунок 1 – Диаграмма контейнеров разработанной системы (нотация C4); зелёным – новое в LP4

nlp-service получил два новых эндпоинта: **POST /translate** (словный перевод текста по переданному словарю плюс частотный список слов для вкладки 1) и **POST /syntax/parse** (дерево синтаксического разбора одного предложения для вкладки 2). Оба эндпоинта, как и остальные операции **nlp-service**, не хранят состояние и не обращаются к БД – словарь передаётся в запросе, а результат возвращается как чистая функция входа. Оркестрацией (кто и когда обращается к словарю, что сохранить в БД) занимается **api**, как и для остальных сценариев системы: новый модуль **application/translation** загружает актуальный словарь из БД, вызывает **nlp-service** и сохраняет результат.

Помимо этого, LP4 расширила ответственность **frontend**:

– новая страница «Перевод» с четырьмя вкладками – собственно перевод, тестовый прогон перевода на коллекции с прогресс-баром (по

аналогии с ЛР2/ЛР3), частотный словарь (вкладка 1), синтаксический разбор предложения (вкладка 2) и утилита пополнения/корректировки словаря;

- отдельный маршрут `/translation/runs/{runId}/sentences/{sentenceIndex}` для отчёта о синтаксическом разборе конкретного предложения – по аналогии с тем, как в проекте прошлого семестра (`corpus-manager`) отдельный маршрут вёл от таблицы предложений к разбору выбранного: вкладка 2 показывает таблицу всех предложений текста, переход к разбору – по клику на строку;

- дерево зависимостей визуализируется библиотекой `reactflow` (перенос компонента `DependencyGraph` из `corpus-manager`, адаптированный под текущий UI-кит) – корень предложения наверху, узлы расположены по уровням BFS-обхода от корня, что даёт настоящее дерево, а не список токенов;

- как и в ЛР3, список документов для выбора реализован комбобоксом с поиском на сервере (`DocumentCombobox`), а не статичной загрузкой коллекции; кнопки «Сохранить в файл» и «Печать» формируют результат в кодировке Unicode без интерфейса приложения.

Структура базы данных

Схема ключевых таблиц и связей между ними показана на рисунке 2 (нотация Crow's Foot); таблицы, добавленные в ЛР4, выделены зелёным.




Рисунок 2 – ER-диаграмма базы данных (нотация Crow's Foot); зелёным – новое в ЛР4

– `translation_dictionary_entries` – собственно словарь переводов: тройка (`source_lemma`, `pos`, `target_text`) на пару языков, с уникальным ограничением по (язык-источник, язык-цель, лемма, часть речи); пополнение и корректировка этой таблицы вынесены в отдельную утилиту интерфейса (см. далее);

– **translation_runs** – один выполненный перевод: либо документа коллекции (**document_id**), либо вставленного текста (**document_id** IS NULL); **collection_id** заполняется в обоих случаях (у документа – берётся из документа, у вставленного текста – из текущей выбранной коллекции), что позволяет восстанавливать последний перевод при повторном открытии страницы для конкретной коллекции; **test_run_id** (нулевой для разового перевода) отличает строку, принадлежащую тестовому прогону, от разового перевода, а **translated_text_word_count** – число слов уже в переведённом тексте, отдельно от **word_count** (слов до перевода) и **translated_word_count** (слов, для которых словарь дал перевод) – подстановка словарной статьи не обязана сохранять число слов (см. далее, «Основные алгоритмы»);

- `translation_test_runs` – тестовый прогон перевода на документах коллекции, чей язык совпадает с исходным языком перевода (статус и прогресс для живого прогресс-бара, по аналогии с `summarization_runs` из ЛР3 и `lang_id_runs` из ЛР2); `translation_runs` с непустым `test_run_id` – строки такого прогона;

– **translation_run_words** – частотный список слов конкретного перевода (вкладка 1): лемма, часть речи, частота и перевод, **rank** – порядок по убыванию частоты, отдельная таблица (а не пересчёт по запросу), т. к. список должен оставаться неизменным при последующем расширении словаря переводов.

Ключевое ограничение `pos`, отличающее реализацию ЛР4 от «наивной» схемы – значение этого столбца никогда не бывает `NULL`: запись «подходит под любую часть речи» кодируется явным значением-часовым `"*`, а не `NULL`. Причина – в PostgreSQL (и в стандарте SQL в целом) `NULL` не равен самому себе с точки зрения уникального ограничения, поэтому две строки с одинаковой леммой и `pos = NULL` не считались бы дубликатом и обе успешно вставились бы, несмотря на `UNIQUE(source_lang, target_lang, source_lemma, pos)` – утилита пополнения словаря молча накапливала бы противоречивые записи для одного и того же слова. Явный часовой-значение не подвержен этой проблеме.

Основные алгоритмы

Выбор типа системы. По варианту реализована система *прямого (пословного) перевода* – исходный текст токенизируется, каждое слово ищется в двуязычном словаре по паре (лемма, часть речи) и заменяется на переводной эквивалент; переводная модель как таковая не строится – единственное используемое знание о языковой паре – таблица переводных соответствий (лемма, часть речи) → перевод, без учёта синтаксиса исходного или целевого языка и без согласования словоформ (см. далее, «Анализ результатов»). Сверх этого дополнительно реализованы система непрямого перевода с трансфером и нейросетевая система (описаны и сравнены с прямым методом в отдельном разделе «Трансферный и нейросетевой методы» далее); до конца текущего раздела речь идёт именно о прямом методе.

Общая схема перевода одного текста показана на рисунке 3; тот же проход по токенам одновременно даёт и переведённый текст, и статистику слов, из которой строится частотный словарь (вкладка 1).




Рисунок 3 – Прямой (пословный) перевод текста и построение частотного словаря (вкладка 1)

Поиск перевода слова и откат по части речи. Для каждого алфавитного токена сначала строится ключ "лемма|POS" (POS – тег, присвоенный spaCy этому конкретному употреблению слова в тексте); если по этому ключу перевод не найден, выполняется повторный поиск по ключу "лемма|*". Второй ключ – не просто откат на случай отсутствия перевода: он присутствует в словаре lookup для каждой леммы, даже если для неё есть один или несколько POS-специфичных переводов – при построении lookup-словаря (`TranslationDictionaryRepository.as_lookup`) для каждой леммы дополнительно устанавливается запись "лемма|*" первым встреченным переводом (записи читаются в порядке возрастания `id`, поэтому вручную добавленные и курируемые переводы предшествуют записям из большого автоматически размеченного словаря и имеют приоритет). Это осознанное решение: словарь размечен POS-тегами для каждого слова *вне*

контекста предложения (см. далее), и тег, присвоенный слову при разметке словаря, не всегда совпадает с тегом, который spaCy присвоит тому же слову в конкретном предложении текста (например, *"run"* может быть размечено в словаре как **VERB**, а в переводимом тексте встретиться как **NOUN**) – без отката по маске слово осталось бы непереверждённым при малейшем расхождении разметки, что не оправдано, когда сам переводной эквивалент в большинстве случаев подходит для слова независимо от точной части речи.

Определение грамматической информации (POS-теги). Функциональность ЛРЗ весеннего семестра (частеречная разметка) в текущей архитектуре уже реализована в `nlp_core.tokenization` через теггер spaCy (`en_core_web_sm`) – она используется без изменений: каждому слову текста присваивается тег из набора Universal POS (**NOUN**, **VERB**, **ADJ**, ...), показанный пользователю как есть, рядом со словом.

Синтаксический разбор предложения (вкладка 2). Портитована и адаптирована функциональность прошлого семестра (`corpus-manager/backend/app/services/text_processor.py`) – разбор строится тем же конвейером spaCy, но с зависимостным парсером (`parser` не отключается, в отличие от основного конвейера токенизации ЛР1–ЛР3, где он исключён ради скорости индексации). Для выбранного предложения каждый токен получает позицию, лемму, POS-тег, синтаксическую роль (`dep_`) и позицию главного слова (`head`); токен без главного слова (сам себе голова) – корень дерева. Фронтенд строит дерево BFS-обходом от корня и раскладывает узлы по уровням глубины, поэтому визуализация – настоящее дерево (рисунок 4), а не плоский список токенов; отдельная таблица под деревом (рисунок 5) дублирует те же данные текстом для удобства чтения и печати.




Рисунок 4 – Вкладка «Синтаксис»: дерево синтаксического разбора выбранного предложения

слово	лемма	POS	роль	главное слово
Recent	recent	ADJ	amod	advances
advances	advance	NOUN	nsubj	improved
in	in	ADP	prep	advances
oncology	oncology	NOUN	pobj	in
have	have	AUX	aux	improved
significantly	significantly	ADV	advmod	improved
improved	improve	VERB	amod	rates
survival	survival	NOUN	compound	rates
rates	rate	NOUN	ROOT	— корень —
for	for	ADP	prep	rates
patients	patient	NOUN	pobj	for
diagnosed	diagnose	VERB	acl	patients
with	with	ADP	prep	diagnosed

Рисунок 5 – Таблица токенов под деревом разбора: слово, лемма, POS, синтаксическая роль, главное слово

Частотный список слов (вкладка 1). Функциональность ЛР1 весеннего семестра (частотный список слов) переиспользована буквально – та же функция токенизации с исключением стоп-слов, что и для индексации документов, только результат группируется по (лемма, POS) и сортируется по убыванию частоты, а не используется для TF-IDF. Каждое слово в списке сопровождается переводом, найденным тем же словарём и по тому же правилу отката, что и в основном переводе (рисунок 6).

#	слово	лемма	POS	ЧАСТОТА	ПЕРЕВОД
1	physician	physician	NOUN	1	médecin
2	carefully	carefully	ADV	1	prudemment
3	examined	examine	VERB	1	examiner
4	elderly	elderly	ADJ	1	âgées
5	patient	patient	NOUN	1	patient
6	diagnosed	diagnose	VERB	1	diagnostiquer
7	rare	rare	ADJ	1	rareté
8	autoimmune	autoimmune	ADJ	1	— нет в словаре —
9	disorder	disorder	NOUN	1	trouble

Рисунок 6 – Вкладка 1: частотный список слов с частью речи и переводом; слово *autoimmune* отсутствует в словаре и явно помечено

Сохранение и восстановление регистра, пунктуации и пробелов. Токенизация spaCy используется не только для лемматизации, но и для

точной реконструкции текста: у каждого токена берётся `whitespace_` (пробел/перевод строки после токена, как он был в исходном тексте), поэтому пунктуация и форматирование переведённого текста совпадают с исходным без дополнительной постобработки; регистр первой буквы и полностью заглавные слова переводного эквивалента подстраиваются под регистр исходного слова.




Рисунок 7 – Вкладка «Перевод»: количество слов и процент переведённых слов вынесены в заголовки карточек исходного текста и перевода

Трансферный и нейросетевой методы (для сравнения)

Трансферный (непрямой) метод. Использует тот же словарь и тот же поиск перевода по (лемма, часть речи) с откатом по маске, что и прямой метод, но перед подстановкой перестраивает дерево синтаксической зависимости (тот же парсер `sraСу`, что и на вкладке 2) по трём правилам грамматики французского языка: большинство прилагательных переносятся после существительного, кроме короткого списка BAGS-прилагательных (*bon, grand, petit* и т. п.), которые, как и в английском, остаются перед ним; отрицание *not/n't* вместе со вспомогательным *do* заменяется на «*ne... pas*» вокруг сказуемого (с элизией *ne* → *n'* перед гласной); предлог сливается с определённым артиклем (*de le* → *du*, *à les* → *aux*). Словарное покрытие не меняется – подстановка слова та же самая, что и в прямом методе, – меняются только порядок слов и грамматические конструкции. На вкладке «Перевод» результат трансферного метода сравнивается с результатом прямого перевода того же текста, и слова, которые правило переставило, вставило или слило, подсвечиваются прямо в тексте перевода – видно, где именно сработало каждое правило.

Нейросетевой метод. Предобученная модель `MarianMT (Helsinki-NLP/opus-mt-en-fr)`, исполняемая локально в отдельном `mt-service` без обращения к внешним API. В отличие от прямого и трансферного методов, двуязычный словарь не используется вообще: текст делится на предложения (тем же сплиттером, что и остальная система), и каждое предложение целиком переводится моделью за один проход, без пословной подстановки. «Слов во входном тексте», «переведено слов» и покрытие словаря по-прежнему считаются для неё по тому же словарю, что и для прямого метода, – но это оценка словарного запаса исходного текста, а не качества нейроперевода (это разные вещи именно потому, что нейросеть в словарь не заглядывает). Для приемлемого времени ответа на CPU модель запущена с жадным декодированием (`num_beams=1` вместо принятых в модели по умолчанию 4 лучей) и динамическим квантованием линейных слоёв до INT8 – вместе это ускоряет перевод в 2–4 раза и вдвое уменьшает вес модели ценой небольшого огрубления связности по сравнению с полным лучевым поиском.

Сводное сравнение всех трёх методов на одной тестовой коллекции – таблица 1.

Таблица 1 – Сравнение методов перевода на коллекции MedicineAndArt (20 англоязычных документов)

Метод	Словарь	Синтаксис	Среднее время документа	Особенность
Прямой	Да	Не учитывается	227 мс	Дословная подстановка, порядок слов исходного языка сохраняется
Трансферный	Да, тот же	Учитывается (перестройка дерева)	592 мс	Тот же словарь, но верный порядок слов, «не. . . ras», слияние предлогов
Нейросетевой	Не используется	Учитывается неявно (внутри модели)	9,7 с	Не ограничен словарём, но связность и терминология не контролируются вручную

Покрытие словаря (91,0 %, таблица 2) у всех трёх методов совпадает, поскольку считается одним и тем же образом по словарю прямого метода независимо от того, использует ли сам метод перевода этот словарь – для нейросетевого метода это оценка лексики исходного текста, а не оценка качества его перевода (см. выше), поэтому столбец с покрытием в сравнении не приведён. Разница во времени между методами – ожидаемая: прямой метод только читает словарь и подставляет готовую строку; трансферный дополнительно строит дерево зависимости (тот же парсер, что и на вкладке 2, но включённый, в отличие от основного конвейера индексации); нейросетевой требует прогона всего текста через модель на CPU и на порядок медленнее обоих словарных методов даже после ускорения декодирования и квантования.

Утилита пополнения и корректировки словаря

Отдельная вкладка «Словарь» – утилита автоматического пополнения/корректировки словаря (таблицы БД): постраничная таблица всех статей словаря с поиском по слову или переводу, добавлением новой статьи (лемма, часть речи – выбор из списка тегов `sraСу` или «любая», перевод, примечание) и редактированием/удалением существующей (рисунок 8). Добавление заведомого дубликата (та же лемма, тот же язык и та же часть речи) отклоняется с кодом 409 – отдельно проверено, что это работает и для часового-значения "*" (см. предыдущий раздел про NULL).




Рисунок 8 – Вкладка «Словарь»: постраничная таблица статей словаря переводов с POS-тегами

Тестовая коллекция документов

Вариант 11 задаёт направление перевода англо-французское и предметную область – научные статьи по медицине и критика предметов изобразительного искусства. Количественная оценка полноты перевода построена на реальной коллекции документов **MedicineAndArt** (60 документов: 20 англоязычных статей об искусстве с **hyperallergic.com** и 40 франкоязычных статей и архивных записей о медицине и искусствоведении с **hal.science** и родственных ресурсов) – настоящий веб-текст предметной области варианта, включая заголовки, имена художников и авторов, названия изданий и другой характерный для реальных документов «шум» (короткий пример перевода отдельного предложения – рисунок 7).

Тестовый прогон перевода на коллекции

По аналогии с ЛР2 (`lang_id_runs`) и ЛР3 (`summarization_runs`), вкладка «Тестирование» запускает перевод одним нажатием: фоновая задача `api` отбирает из коллекции документы, чей язык (`documents.language`, определённый при кроулинге – см. ЛР1/ЛР2) совпадает с исходным языком перевода, последовательно переводит каждый такой документ, сохраняет результат (`translation_runs` с непустым `test_run_id`) и обновляет `documents_processed` записи `translation_test_runs` – вкладка отражает прогресс живым прогресс-баром через WebSocket с откатом на поллинг при разрыве соединения (рисунок 9), как и аналогичные тестовые прогоны в ЛР2/ЛР3. Документы на других языках в тестовый прогон не попадают: слова текста не на исходном языке перевода почти никогда не находятся в словаре по построению (поиск идёт по «чужой» лемме), и без этого отбора они только искажали бы среднее покрытие словаря, не отражая его реальной полноты. Средние по коллекции число слов до и после перевода, покрытие словаря и время перевода, а также разбивка по документам с экспортом в CSV/JSON и печатью показываются на странице «Метрики» (рисунок 10) – по аналогии с тем, как там же показаны метрики реферирования ЛР3.




Рисунок 9 – Вкладка «Тестирование»: перевод англоязычных документов коллекции с живым прогресс-баром




Рисунок 10 – Страница «Метрики»: средние показатели последнего тестового прогона на коллекции и результаты по документам

Результаты тестирования и оценка качества

Пополнение словаря реальными данными. Стартовый вручную курируемый словарь (служебные слова английского языка, общая научная лексика и порядка 100 терминов медицины/искусствоведения) содержит 311 статей и расширен реальным двуязычным словарём MUSE (Facebook Research, github.com/facebookresearch/MUSE, 113 286 пар слов – по несколько альтернативных переводов на слово): для каждого из 94 681 уникальных исходных слов взят первый (наиболее частотный по построению словаря MUSE) перевод, каждое слово размечено частью речи *вне контекста предложения* тем же конвейером spaCy (пакетно, единым проходом `nlp.pipe`), и переводы объединены по паре (лемма, часть речи), а не по словоформе – 87 729 таких пар. Итоговый словарь – курируемые 311 статей плюс все 87 729 пар MUSE, за вычетом 249 пар, для которых уже есть курируемая статья с той же леммой и частью речи, – 87 791 статья, без ограничения по частоте исходного слова.

Коллекция **MedicineAndArt** (см. выше) содержит 60 документов, из которых 20 размечены при кроулинге как англоязычные; тестовый прогон перевода отбирает именно эти 20 и даёт по ним среднее покрытие словаря 91,0 % (таблица 2).

Таблица 2 – Средние показатели тестового прогона перевода на коллекции MedicineAndArt

Метрика	Значение
Документов переведено	20
Среднее число слов до перевода	805,9
Среднее число слов после перевода	849,8
Среднее покрытие словаря	91,0 %
Среднее время перевода документа	229,8 мс

Оставшиеся непереведёнными слова англоязычных документов – узкоспециализированные термины и редкие имена собственные, которых нет в словаре MUSE (например, *autoimmune*, рисунок 6) – ожидаемый результат для системы прямого перевода: её словарь конечен по построению, и утилита пополнения словаря (см. выше) – предусмотренный способ закрыть именно такие случаи вручную, не переобучая никакую модель.

Время выполнения. Словарь содержит 87 791 статью; так как TranslationDictionaryRepository.as_lookup строит lookup-словарь из записей БД заново при каждом переводе и не кеширует его между запросами, эта стоимость целиком входит во время перевода (таблица 2, рисунок 10); кеширование lookup-словаря между запросами – в списке улучшений ниже.

Анализ результатов и предложения по улучшению

а) **Размер словаря – определяющий фактор качества системы прямого перевода.** Курируемый словарь общего назначения (311 статей) покрывает служебные слова и общую лексику, но не специализированную терминологию предметной области; практическое покрытие обеспечивает объединение с MUSE – 87 791 статья без ограничения по частоте исходного слова. Для систем этого класса именно размер и полнота словаря, а не правило подстановки, являются узким местом качества: на англоязычных документах тестовой коллекции MedicineAndArt среднее покрытие составляет 91,0 % (таблица 2) при неизменном алгоритме перевода.

б) **POS-тегирование словаря вне контекста предложения – компромисс, а не идеальное решение.** Присвоение одной части речи каждому слову словаря (без учёта контекста, в котором оно встретится в переводимом тексте) неизбежно даёт часть словаря с «неверной» на первый взгляд частью речи для конкретного предложения; это компенсируется откатом по маске "*" (см. выше), ценой которого является то, что для омонимов с разным переводом в разных частях речи (например, существительное и глагол с общим написанием) может быть выбран перевод не той

формы. Хранение нескольких переводов на лемму (а не одного, выбираемого правилом отката) устранило бы эту проблему ценой усложнения структуры словаря и интерфейса его редактирования.

в) Что можно добавить в систему для её улучшения.

– согласование словоформы перевода с исходным словом (число, время, падеж) – сейчас переводной эквивалент подставляется в начальной форме, взятой из словаря, без склонения/спряжения под грамматическую форму исходного слова;

– кеширование lookip-словаря между запросами перевода (сейчас все 87 791 записей перечитываются из БД при каждом переводе, см. «Время выполнения») – ускорило бы обработку текстов на коллекциях с частыми повторными переводами;

– статистика по словарю (доля непереведённых слов по последним N переводам) прямо на вкладке «Словарь» – подсказывала бы, какие слова стоит добавить в первую очередь, вместо ручного просмотра частотного списка после каждого перевода;

– предметно-ориентированные дополнения словаря (аннотированные списки терминов конкретно по онкологии, кардиологии, критике живописи и т. д.) – в общем словаре MUSE специализированная современная терминология представлена слабо (см. *autoimmune* выше), и закрыть такие пробелы может только предметно-ориентированное пополнение через утилиту редактирования словаря.

г) Где систему можно применить.

– черновой перевод документов информационно-поисковой системы ЛР1 для быстрого ознакомления с содержанием перед выбором, читать ли документ полностью на исходном языке;

– учебный полигон для сравнения с более сложными архитектурами машинного перевода – трансферной и нейросетевой, реализованными и сравненными с прямым методом выше (раздел «Трансферный и нейросетевой методы», таблица 1): прямой перевод даёт понятную базовую линию качества и явно показывает, какие именно случаи (согласование форм, многозначные слова, отсутствующая лексика) требуют более сложной модели;

– источник частотного словаря предметной области (вкладка 1) как самостоятельный инструмент – например, для быстрой оценки того, насколько текст на входном языке относится к уже освоенной словарём терминологии.

Использованные готовые компоненты

Таблица 3 – Библиотеки, готовые данные и программные средства, использованные при реализации ЛР4 (дополнительно к перечисленным в отчётах по ЛР1–ЛР3)

Компонент	Назначение
sраСу (теггер и парсер)	POS-теги для частотного словаря и перевода (теггер <code>en_core_web_sm</code> , без изменений переиспользован из ЛР3) и дерево зависимостей для вкладки 2 и трансферного метода перевода (парсер, для основного конвейера индексации отключаемый ради скорости, здесь включается отдельно).
MUSE (Facebook Research)	Источник реального двуязычного словаря <code>en-fr</code> (113 286 пар слов, github.com/facebookresearch/MUSE) для пополнения стартового курируемого словаря (см. «Пополнение словаря реальными данными» выше).
reactflow	Визуализация дерева синтаксического разбора (вкладка 2) – перенос идеи компонента <code>DependencyGraph</code> из <code>corpus-manager</code> , переписанного под текущий UI-кит проекта.
Helsinki-NLP/opus-mt-en-fr (transformers, PyTorch)	Предобученная модель MarianMT для нейросетевого метода перевода, выполняется локально в <code>mt-service</code> ; жадное декодирование и динамическое INT8-квантование – для приемлемого времени ответа на CPU (см. «Трансферный и нейросетевой методы» выше).

Выводы

В ходе выполнения лабораторной работы реализована система автоматического машинного перевода текстов по варианту 11 (направление англо-французское, предметная область – научные статьи по медицине и

критика предметов изобразительного искусства) как новый сценарий использования поверх архитектуры, разработанной в ЛР1–ЛР3. Для прямого и трансферного методов перевода отдельный микросервис не понадобился, в отличие от ЛР2 и ЛР3: обе операции без состояния над spaCy, как уже существующие в **nlp-service** токенизация и лемматизация, поэтому они естественно расширили этот сервис, а не потребовали нового; нейросетевой метод (см. ниже) – исключение, для него добавлен отдельный **mt-service**. Ни один существующий контракт системы (поиск, краулинг, определение языка, реферирование) при этом не был нарушен.

Реализована система прямого (пословного) перевода: каждое слово текста ищется в двуязычном словаре по паре (лемма, часть речи) с откатом на запись «любая часть речи», если точное совпадение не найдено – откат компенсирует то, что словарь размечен частями речи вне контекста конкретного предложения. Определяющим фактором качества такой системы является размер словаря, а не сам алгоритм подстановки: словарь объединяет стартовый курируемый список (311 статей) с реальным двуязычным словарём MUSE, размеченным частями речи через spaCy (итог – 87 791 статья, без ограничения по частоте исходного слова), и даёт среднее покрытие 91,0 % на реальной тестовой коллекции (табл. 2). Отдельно решена сопутствующая проблема корректности: значение «любая часть речи» в столбце **pos** хранится явным значением-часовым, а не NULL – в PostgreSQL NULL не равен самому себе для уникального ограничения, из-за чего утилита пополнения словаря могла бы молча копить противоречивые дубликаты записей для одного и того же слова.

Сверх обязательного по варианту прямого метода дополнительно реализованы и сравнены на той же тестовой коллекции ещё два типа систем: непрямой перевод с трансфером (тот же словарь, но дерево зависимости перестраивается по трём правилам грамматики французского языка – порядок прилагательных, отрицание «не... pas», слияние предлога с артиклем) и нейросетевой перевод локальной предобученной моделью MarianMT без словаря вообще. Сравнение (табл. 1) подтверждает ожидаемый компромисс: трансферный метод стоит прямому методу порядка вдвое большего времени (592 мс против 227 мс на документ) за счёт построения дерева зависимости, но исправляет порядок слов и грамматические конструкции, которые прямой перевод оставляет дословными; нейросетевой метод на порядок медленнее обоих словарных методов (9,7 с на документ даже после перехода на жадное декодирование и INT8-квантование), зато не ограничен словарём вообще.

По аналогии с тестовыми прогонами ЛР2 (**lang_id_runs**) и ЛР3 (**summarization_runs**) добавлена вкладка «Тестирование»: перевод коллекции одним нажатием, живой прогресс-бар через WebSocket и средние метрики (число слов до и после перевода, покрытие словаря, время) на

странице «Метрики». Тестовый прогон использует уже существующую в системе разметку языка документа (`documents.language`, определённую при кроулинге – см. ЛР1/ЛР2) и переводит только документы на исходном языке перевода; документы на других языках коллекции в прогон не попадают, поскольку их слова почти никогда не находятся в словаре по построению (поиск идёт по лемме «чужого» языка) и только искажали бы среднее покрытие словаря.

Обе дополнительные вкладки задания используют уже существующую в проекте функциональность: частотный список слов (вкладка 1) переиспользует тот же конвейер токенизации с исключением стоп-слов, что и индексация документов ЛР1, а дерево синтаксического разбора (вкладка 2) – перенесённый и адаптированный из проекта прошлого семестра (`corpus-manager`) конвейер spaCy с включённым зависимостным парсером (в основном конвейере индексации он отключён ради скорости). POS-теги и синтаксические роли выводятся как сырые значения spaCy без перевода на русский язык – решение, взятое из исходного `corpus-manager` и сознательно сохранённое, поскольку расшифровка тега поверх уже переведённого текста избыточна для читателя, знакомого с разметкой Universal POS. Отдельная утилита пополнения/корректировки словаря (постраничная таблица с поиском, добавлением, редактированием и удалением статей) была фактически задействована в ходе самой лабораторной работы – отсутствующие в словаре слова предметной области (например, специализированные медицинские термины) добавлялись в БД без переразвёртывания системы.