

Министерство образования Республики Беларусь

Учреждение образования
«БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ»

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

Лабораторная работа №4

по дисциплине «Естественно-языковой интерфейс интеллектуальных
систем»

на тему «Автоматический машинный перевод текстов
(вариант 11)»

Выполнили студенты гр. 321701

Ковальчук В. Н.
Самович В. М.

Проверил

Крапивин Ю. Б.

Минск 2026

Цель: освоить на практике основные принципы машинного перевода документов.

Задание (вариант 11): разработать систему автоматического машинного перевода текстов со следующей комбинацией признаков варианта:

- **Направление перевода** – англо-французский;
- **Предметная область** – научные статьи по медицине, критика предметов изобразительного искусства.

Согласно методическим указаниям, система должна:

- на входе принимать естественно-языковой текст на входном языке, подлежащий машинному переводу;
- подсчитывать количество слов во входном тексте и количество переведённых слов, а также определять грамматическую информацию (теги частей речи и их расшифровку – с использованием функциональности ЛРЗ весеннего семестра, POS-теги);
- на выходе выдавать:
 - а) перевод входного текста на выходной язык;
 - б) упорядоченный по частоте встречаемости в тексте список слов и их переводов на выходной язык с грамматической информацией (*вкладка 1*, с использованием функциональности ЛР1 весеннего семестра – частотный список слов);
 - в) построенное дерево синтаксического разбора выбранного предложения (*вкладка 2*);
- обеспечивать наличие утилиты автоматического пополнения/корректировки полученного словаря (таблицы БД);
- обеспечивать сохранение и распечатку результатов перевода и упорядоченных по частоте встречаемости в тексте списков слов и их переводов на выходной язык с грамматической информацией в файл формата txt кодировки Unicode;
- иметь простой и доступный пользовательский интерфейс с понятным набором инструментов.

Из трёх типов систем машинного перевода, описанных в методических указаниях (системы прямого перевода, системы непрямого перевода – с трансфером или языком-посредником, системы, основанные на знаниях), для реализации выбрана **система прямого (пословного) перевода**: исходный текст токенизируется, каждое слово ищется в двуязычном словаре по паре (лемма, часть речи) и заменяется на переводной эквивалент; переводная модель как таковая не используется, учитывается лишь локальный контекст (грамматическая форма слова через POS-тег).

Структура разработанной системы

Машинный перевод реализован как новый сценарий использования поверх архитектуры ЛР1–ЛР3 (см. docs/ARCHITECTURE.md): границы сервисов по-прежнему проведены по зоне ответственности, а не по лабораторной работе. В отличие от ЛР2 (lang-id-service) и ЛР3 (summarization-service), для ЛР4 не понадобился отдельный микросервис – перевод по словарю и синтаксический разбор предложения являются такими же операциями «текст на входе – разбор spaCy – чистый результат на выходе», как токенизация и лемматизация, поэтому они естественно легли в уже существующий `nlp-service`, а хранение словаря и истории переводов – в уже существующий `api`. Структура системы на уровне контейнеров (С4, уровень 2) показана на рисунке 1; связи, добавленные именно в этой лабораторной работе, выделены зелёным цветом.




Рисунок 1 – Диаграмма контейнеров разработанной системы (нотация С4); зелёным – новое в ЛР4

nlp-service получил два новых эндпоинта: **POST /translate** (словный перевод текста по переданному словарю плюс частотный список слов для вкладки 1) и **POST /syntax/parse** (дерево синтаксического разбора одного предложения для вкладки 2). Оба эндпоинта, как и остальные операции **nlp-service**, не хранят состояние и не обращаются к БД – словарь передаётся в запросе, а результат возвращается как чистая функция входа. Оркестрацией (кто и когда обращается к словарю, что сохранить в БД) занимается **api**, как и для остальных сценариев системы: новый модуль **application/translation** загружает актуальный словарь из БД, вызывает **nlp-service** и сохраняет результат.

Помимо этого, ЛР4 расширила ответственность **frontend**:

- новая страница «Перевод» с четырьмя вкладками – собственно перевод, частотный словарь (вкладка 1 методички), синтаксический разбор предложения (вкладка 2) и утилита пополнения/корректировки словаря;
- отдельный маршрут **/translation/runs/{runId}/sentences/{sentenceIndex}** для отчёта о синтаксическом разборе конкретного предложения – по аналогии с тем, как в проекте прошлого семестра (**corpus-manager**) отдельный маршрут вёл от таблицы предложений к разбору выбранного: вкладка 2 показывает таблицу всех предложений текста, переход к разбору – по клику на строку;
- POS-теги и синтаксические роли зависимостей выводятся как есть (сырые значения spaCy – **NOUN**, **VERB**, **nsubj**, **ROOT** и т. д.), без перевода на русский язык – то же решение, что и в исходном **corpus-manager**: расшифровка тега добавляет шаг перевода термина поверх уже переведённого текста, что избыточно для читателя, знакомого с разметкой Universal POS;
- дерево зависимостей визуализируется библиотекой **reactflow** (перенос компонента **DependencyGraph** из **corpus-manager**, адаптированный под текущий UI-кит) – корень предложения наверху, узлы расположены по уровням BFS-обхода от корня, что даёт настоящее дерево, а не список токенов;
- как и в ЛР3, список документов для выбора реализован комбобоксом с поиском на сервере (**DocumentCombobox**), а не статичной загрузкой коллекции; кнопки «Сохранить в файл» и «Печать» формируют результат в кодировке Unicode без интерфейса приложения.

Структура базы данных

Схема ключевых таблиц и связей между ними показана на рисунке 2 (нотация Crow's Foot); таблицы, добавленные в ЛР4, выделены зелёным.




Рисунок 2 – ER-диаграмма базы данных (нотация Crow's Foot); зелёным – новое в ЛР4

- `translation_dictionary_entries` – собственно словарь переводов: тройка (`source_lemma`, `pos`, `target_text`) на пару языков, с уникальным ограничением по (язык-источник, язык-цель, лемма, часть речи) – это и есть «таблица БД», пополнение и корректировку которой методичка требует вынести в отдельную утилиту интерфейса;

– `translation_runs` – один выполненный перевод: либо документа коллекции (`document_id`), либо вставленного текста (`document_id` IS NULL); `collection_id` заполняется в обоих случаях (у документа – берётся из документа, у вставленного текста – из текущей выбранной коллекции), что позволяет восстанавливать последний перевод при повторном открытии страницы для конкретной коллекции;

– **translation_run_words** – частотный список слов конкретного перевода (вкладка 1): лемма, часть речи, частота и перевод, **rank** – порядок по убыванию частоты, отдельная таблица (а не пересчёт по запросу), т. к. список должен оставаться неизменным при последующем расширении словаря переводов.

Ключевое ограничение **pos**, отличающее реализацию ЛР4 от «наивной» схемы – значение этого столбца никогда не бывает NULL: запись «подходит под любую часть речи» кодируется явным значением-часовым **"***", а не NULL. Причина – в PostgreSQL (и в стандарте SQL в целом) NULL не равен самому себе с точки зрения уникального ограничения, поэтому две строки с одинаковой леммой и **pos = NULL** не считались бы дубликатом и обе успешно вставились бы, несмотря на **UNIQUE(source_lang, target_lang, source_lemma, pos)** – утилита пополнения словаря молча накапливала бы противоречивые записи для одного и того же слова. Явный часовой-значение не подвержен этой проблеме.

Основные алгоритмы

Выбор типа системы. Из трёх типов систем машинного перевода, описанных в методических указаниях, реализована система *прямого (пословного) перевода* – исходный текст токенизируется, каждое слово ищется в двуязычном словаре по паре (лемма, часть речи) и заменяется на переводной эквивалент; переводная модель как таковая не строится, что соответствует определению методички («операция перевода требует минимума преобразований... никакая переводная модель не используется за исключением переводных соответствий»).

Общая схема перевода одного текста показана на рисунке 3; тот же проход по токенам одновременно даёт и переведённый текст, и статистику слов, из которой строится частотный словарь (вкладка 1).




Рисунок 3 – Прямой (пословный) перевод текста и построение частотного словаря (вкладка 1)

Поиск перевода слова и откат по части речи. Для каждого

алфавитного токена сначала строится ключ "**лемма|POS**" (POS – тег, присвоенный spaCy этому конкретному употреблению слова в тексте); если по этому ключу перевод не найден, выполняется повторный поиск по ключу "**лемма|***". Второй ключ – не просто откат на случай отсутствия перевода: он присутствует в словаре lookup *для каждой леммы*, даже если для неё есть один или несколько POS-специфичных переводов – при построении lookup-словаря (`TranslationDictionaryRepository.as_lookup`) для каждой леммы дополнительно устанавливается запись "**лемма|***" первым встреченным переводом (записи читаются в порядке возрастания `id`, поэтому вручную добавленные и курируемые переводы предшествуют записям из большого автоматически размеченного словаря и имеют приоритет). Это осознанное решение: словарь размечен POS-тегами для каждого слова *вне контекста предложения* (см. далее), и тег, присвоенный слову при разметке словаря, не всегда совпадает с тегом, который spaCy присвоит тому же слову в конкретном предложении текста (например, "*run*" может быть размечено в словаре как **VERB**, а в переводимом тексте встретиться как **NOUN**) – без отката по маске слово осталось бы непереведённым при малейшем расхождении разметки, что не оправдано, когда сам переводной эквивалент в большинстве случаев подходит для слова независимо от точной части речи.

Определение грамматической информации (POS-теги). Функциональность ЛРЗ весеннего семестра (частеречная разметка) в текущей архитектуре уже реализована в `nlp_core.tokenization` через теггер spaCy (`en_core_web_sm`) – она используется без изменений: каждому слову текста присваивается тег из набора Universal POS (**NOUN**, **VERB**, **ADJ**, ...), показанный пользователю как есть, рядом со словом.

Синтаксический разбор предложения (вкладка 2). Портитована и адаптирована функциональность прошлого семестра (`corpus-manager/backend/app/services/text_processor.py`) – разбор строится тем же конвейером spaCy, но *с зависимостным парсером* (`parser` не отключается, в отличие от основного конвейера токенизации ЛР1–ЛР3, где он исключён ради скорости индексации). Для выбранного предложения каждый токен получает позицию, лемму, POS-тег, синтаксическую роль (`dep_`) и позицию главного слова (`head`); токен без главного слова (сам себе голова) – корень дерева. Фронтенд строит дерево BFS-обходом от корня и раскладывает узлы по уровням глубины, поэтому визуализация – настоящее дерево (рисунок 4), а не плоский список токенов; отдельная таблица под деревом (рисунок 5) дублирует те же данные текстом для удобства чтения и печати.




Рисунок 4 – Вкладка «Синтаксис»: дерево синтаксического разбора выбранного предложения

слово	лемма	POS	роль	главное слово
Recent	recent	ADJ	amod	advances
advances	advance	NOUN	nsubj	improved
in	in	ADP	prep	advances
oncology	oncology	NOUN	pobj	in
have	have	AUX	aux	improved
significantly	significantly	ADV	advmod	improved
improved	improve	VERB	amod	rates
survival	survival	NOUN	compound	rates
rates	rate	NOUN	ROOT	— корень —
for	for	ADP	prep	rates
patients	patient	NOUN	pobj	for
diagnosed	diagnose	VERB	acl	patients
with	with	ADP	prep	diagnosed

Рисунок 5 – Таблица токенов под деревом разбора: слово, лемма, POS, синтаксическая роль, главное слово

Частотный список слов (вкладка 1). Функциональность ЛР1 весеннего семестра (частотный список слов) переиспользована буквально – та же функция токенизации с исключением стоп-слов, что и для индексации документов, только результат группируется по (лемма, POS) и сортируется по убыванию частоты, а не используется для TF-IDF. Каждое слово в списке сопровождается переводом, найденным тем же словарём и по тому же правилу отката, что и в основном переводе (рисунок 6).




Рисунок 6 – Вкладка 1: частотный список слов с частью речи и переводом; слово *autoimmune* отсутствует в словаре и явно помечено

Сохранение и восстановление регистра, пунктуации и пробелов. Токенизация `sraСу` используется не только для лемматизации, но и для точной реконструкции текста: у каждого токена берётся `whitespace_` (пробел/перевод строки после токена, как он был в исходном тексте), поэтому пунктуация и форматирование переведённого текста совпадают с исходным без дополнительной постобработки; регистр первой буквы и полностью заглавные слова переводного эквивалента подстраиваются под регистр исходного слова.





Рисунок 7 – Вкладка «Перевод»: количество слов и процент переведённых слов вынесены в заголовки карточек исходного текста и перевода

Утилита пополнения и корректировки словаря

Отдельная вкладка «Словарь» – утилита, явно требуемая методичкой («обеспечить наличие утилиты автоматического пополнения/корректировки полученного словаря (таблицы БД)»): постраничная таблица всех статей словаря с поиском по слову или переводу, добавлением новой статьи (лемма, часть речи – выбор из списка тегов sраСу или «любая», перевод, примечание) и редактированием/удалением существующей (рисунок 8). Добавление заведомого дубликата (та же лемма, тот же язык и та же часть речи) отклоняется с кодом 409 – отдельно проверено, что это работает и для часового-значения "*" (см. предыдущий раздел про NULL).



Автоматический машинный перевод текстов

Система прямого (пословного) перевода английский – французский для научных статей по медицине и критики произведений изобразительного искусства (вариант 11): подсчет слов, частотный словарь с грамматической информацией и переводом, дерево синтаксического разбора предложения и утилита пополнения словаря.

Перевод Слова Синтаксис Словарь

Словарь переводов (EN – FR)

Утилита пополнения и корректировки словаря, используемого системой прямого (пословного) перевода — добавляйте отсутствующие слова или исправляйте переводы, чтобы повысить полноту перевода без переобучения какой-либо модели.

Q Поиск по слову или переводу... + Добавить слово

СЛОВО	POS	ПЕРЕВОД		
a	DET	un		
aaa	NOUN	aaa		
aah	PROPN	aah		
aang	PROPN	aang		
aardvark	PROPN	aardvark		
aaron	ADP	aaron		
aba	PROPN	aba		

Рисунок 8 – Вкладка «Словарь»: постраничная таблица статей словаря переводов с POS-тегами

Тестовые тексты предметной области

Вариант 11 задаёт направление перевода англо-французское и предметную область – научные статьи по медицине и критика предметов изобразительного искусства. Для тестирования подготовлено по одному характерному тексту каждой области (научообразный абзац о клиническом исследовании в онкологии – 98 слов; искусствоведческий абзац о выставке современной живописи – 107 слов), не входящих в исходные данные, на которых строился словарь (см. далее) – это тексты именно той тематики, для которой методичка требует оценить полноту перевода.

Результаты тестирования и оценка качества

Пополнение словаря реальными данными. Стартовый вручную курируемый словарь (служебные слова английского языка, общая научная лексика и порядка 100 терминов медицины/искусствоведения) содержал всего 311 статей и переводил лишь около половины слов реального текста предметной области (таблица 1). Он был расширен реальным двуязычным словарём MUSE (Facebook Research, 113 286 пар слов), отфильтрованным до топ-50 000 самых частотных слов английского языка (по корпусу субтитров hermitdave/FrequencyWords) – это отсекло длинный хвост из имён собственных, топонимов и аббревиатур, случайно попавших в MUSE вместе с полезной лексикой. Каждое из оставшихся 33 960 слов размечено частью речи *вне контекста предложения* через тот же конвейер spaCy (пакетно, единым проходом `nlp.pipe`); итоговый словарь – 34 050 статей.

Таблица 1 – Полнота перевода тестовых текстов предметной области до и после пополнения словаря

Словарь	Статей	Медицинский текст	Искусствоведческий текст
Только курируемый (стартовый)	311	54/98 слов (55,1 %)	78/107 слов (72,9 %)
Курируемый + MUSE (топ-50к слов)	34 050	93/98 слов (94,9 %)	106/107 слов (99,1 %)

Оставшиеся непереведёнными слова в обоих текстах – узкоспециализированные термины вне топ-50 000 частотных слов языка (например, *autoimmune* в медицинском тексте, рисунок 6) – ожидаемый результат для системы прямого перевода: её словарь конечен по построению, и утилита пополнения словаря (см. выше) – предусмотренный методичкой способ закрыть именно такие случаи вручную, не переобучая никакую модель.

Время выполнения. Перевод обоих тестовых текстов (98 и 107 слов) занял 78,6 мс и 75,6 мс соответственно, включая обращение к `nlp-service` по HTTP; построение словаря `lookup` из 34 050 записей БД при каждом переводе не кешируется и укладывается в то же время – отдельного узкого места по производительности на текстах такого объёма не выявлено.

Анализ результатов и предложения по улучшению

а) **Размер словаря – определяющий фактор качества системы прямого перевода.** Рост словаря в 109 раз (с 311 до 34 050 статей) поднял полноту перевода тестовых текстов с 55–73 % до 95–99 % (таблица 1) при том, что сам алгоритм перевода не менялся – для систем этого класса словарь, а не правило подстановки, является узким местом качества, что прямо следует из определения пословного перевода в методичке.

б) **POS-тегирование словаря вне контекста предложения – компромисс, а не идеальное решение.** Присвоение одной части речи каждому слову словаря (без учёта контекста, в котором оно встретится в переводимом тексте) неизбежно даёт часть словаря с «неверной» на первый взгляд частью речи для конкретного предложения; это компенсируется откатом по маске "*" (см. выше), ценой которого является то, что для омонимов с разным переводом в разных частях речи (например, существительное и глагол с общим написанием) может быть выбран перевод не той формы. Хранение нескольких переводов на лемму (а не одного, выбираемого правилом отката) устранило бы эту проблему ценой усложнения структуры словаря и интерфейса его редактирования.

в) **Что можно добавить в систему для её улучшения.**

- согласование словоформы перевода с исходным словом (число, время, падеж) – сейчас переводной эквивалент подставляется в начальной форме, взятой из словаря, без склонения/спряжения под грамматическую форму исходного слова;

- кеширование `lookup`-словаря между запросами перевода (сейчас все 34 050 записей перечитываются из БД при каждом переводе) – ускорило бы обработку текстов на коллекциях с частыми повторными переводами;

- статистика по словарю (доля непереведённых слов по последним N переводам) прямо на вкладке «Словарь» – подсказывала бы, какие слова стоит добавить в первую очередь, вместо ручного просмотра частотного списка после каждого перевода;

- предметно-ориентированные дополнения словаря (аннотированные списки терминов конкретно по онкологии, кардиологии, критике живописи и т. д.) вместо общего словаря топ-50 000 слов – подняли бы полноту перевода

специализированной лексики предметной области варианта без раздувания словаря общеупотребительными словами, которых там уже достаточно.

г) **Где систему можно применить.**

– черновой перевод документов информационно-поисковой системы ЛР1 для быстрого ознакомления с содержанием перед выбором, читать ли документ полностью на исходном языке;

– учебный полигон для сравнения с более сложными архитектурами машинного перевода (системы с трансфером, нейросетевые модели) – прямой перевод даёт понятную базовую линию качества и явно показывает, какие именно случаи (согласование форм, многозначные слова, отсутствующая лексика) требуют более сложной модели;

– источник частотного словаря предметной области (вкладка 1) как самостоятельный инструмент – например, для быстрой оценки того, насколько текст на входном языке относится к уже освоенной словарём терминологии.

Использованные готовые компоненты

Таблица 2 – Библиотеки, готовые данные и программные средства, использованные при реализации ЛР4 (дополнительно к перечисленным в отчётах по ЛР1–ЛР3)

Компонент	Назначение
sраСу (теггер и парсер)	POS-теги для частотного словаря и перевода (теггер <code>en_core_web_sm</code> , без изменений переиспользован из ЛР3) и дерево зависимостей для вкладки 2 (парсер, для основного конвейера индексации отключаемый ради скорости, здесь включается отдельно).
MUSE (Facebook Research)	Источник реального двуязычного словаря en-fr (113 286 пар слов, github.com/facebookresearch/MUSE) для пополнения стартового курируемого словаря.
FrequencyWords (hermitdave)	Список топ-50 000 слов английского языка по частоте в корпусе субтитров (github.com/hermitdave/FrequencyWords) – фильтр для отсеечения имён собственных/топонимов/аббревиатур из MUSE.
reactflow	Визуализация дерева синтаксического разбора (вкладка 2) – перенос идеи компонента <code>DependencyGraph</code> из <code>corpus-manager</code> , переписанного под текущий UI-кит проекта.

Выводы

В ходе выполнения лабораторной работы реализована система автоматического машинного перевода текстов по варианту 11 (направление англо-французское, предметная область – научные статьи по медицине и критика предметов изобразительного искусства) как новый сценарий использования поверх архитектуры, разработанной в ЛР1–ЛР3. В отличие от ЛР2 и ЛР3, для перевода не понадобился отдельный микросервис: пословный перевод по словарю и синтаксический разбор предложения – такие же операции без состояния над sраСу, как уже существующие в `nlp-service` токенизация и лемматизация, поэтому они естественно расширили этот сервис, а не потребовали нового; ни один существующий контракт системы (поиск, краулинг, определение языка, реферирование) при этом не был нарушен.

Реализована система прямого (пословного) перевода: каждое слово текста ищется в двуязычном словаре по паре (лемма, часть речи) с откатом на запись «любая часть речи», если точное совпадение не найдено – откат компенсирует то, что словарь размечен частями речи вне контекста конкретного предложения. Определяющим фактором качества такой системы

оказался размер словаря, а не сам алгоритм подстановки: расширение стартового курируемого словаря (311 статей) реальным двуязычным словарём MUSE, отфильтрованным до топ-50 000 частотных слов английского языка и размеченным частями речи через spaCy (итог – 34 050 статей), подняло полноту перевода двух тестовых текстов предметной области варианта с 55–73 % до 95–99 % (табл. 1) без единого изменения кода перевода. Отдельно решена сопутствующая проблема корректности: значение «любая часть речи» в столбце **pos** хранится явным значением-часовым, а не NULL – в PostgreSQL NULL не равен самому себе для уникального ограничения, из-за чего утилита пополнения словаря могла бы молча копить противоречивые дубликаты записей для одного и того же слова.

Обе дополнительные вкладки, требуемые методичкой, используют уже существующую в проекте функциональность: частотный список слов (вкладка 1) переиспользует тот же конвейер токенизации с исключением стоп-слов, что и индексация документов ЛР1, а дерево синтаксического разбора (вкладка 2) – перенесённый и адаптированный из проекта прошлого семестра (**corpus-manager**) конвейер spaCy с включённым зависимым парсером (в основном конвейере индексации он отключён ради скорости). POS-теги и синтаксические роли выводятся как сырые значения spaCy без перевода на русский язык – решение, взятое из исходного **corpus-manager** и сознательно сохранённое, поскольку расшифровка тега поверх уже переведённого текста избыточна для читателя, знакомого с разметкой Universal POS. Отдельная утилита пополнения/корректировки словаря (постраничная таблица с поиском, добавлением, редактированием и удалением статей) закрывает соответствующее требование методички и была фактически задействована в ходе самой лабораторной работы – отсутствующие в словаре слова предметной области (например, специализированные медицинские термины) добавлялись в БД без переразвёртывания системы.