

Лабораторная работа

«Автоматическое распознавание языка текста»

Цель работы – изучить и отработать практические навыки применения методов автоматического распознавания языка текстовых документов.

Краткие теоритические сведения.

Наиболее известные в настоящее время методы определения языка текстового документа подчиняются одинаковому принципу, описать который с помощью терминологии информационного поиска можно следующим образом. Во-первых, для каждого естественного языка из конечного набора языков, участвующих в процессе идентификации, строится поисковый образ языка (ПОЯ), во-вторых, для каждого анализируемого (входного) документа в соответствии с правилами построения ПОЯ создаётся поисковый образ документа и, в-третьих, выбирается стратегия сравнения ПОД и ПОЯ, на основании которой и выносится решение о принадлежности входного документа определенному языку.

В зависимости от применяемых правил построения поисковых образов и стратегий их сравнения различают следующие основные методы распознавания языка текстовых документов, ориентированные на использование знаний о естественном языке (ЕЯ) в пределах от уровня алфавита до лексико-грамматического уровня глубины ЕЯ, что вполне приемлемо по трудоёмкости для их использования в промышленных системах автоматической обработки текста: коротких слов, частотных слов, N-грамм, алфавитный, грамматических слов, неграмматических слов.

Метод N-грамм.

В 1994 году В. Канвар и Дж. Тренкл [<http://odur.let.rug.nl/~vannoord/TextCat/textcat.pdf>] предложили метод для определения языка и кодировки документа по его содержанию основываясь на статистиках документов, для которых язык и кодировка известны заранее. Метод основывается на подсчете частот N-грамм (подстрок длины не более N) и предположении, что примерно 300 самых частоиспользуемых N-грамм сильно зависят от языка.


В основе этого метода лежит Закон Зипфа – эмпирическая закономерность распределения частоты слов естественного языка: если все слова языка (или просто достаточно длинного текста) упорядочить по убыванию частоты их использования, то частота n -го слова в таком списке окажется приблизительно обратно пропорциональной его порядковому номеру n (так называемому *рангу* этого слова). Например, первое по используемости слово встречается примерно в два раза чаще, чем второе, и в три раза чаще, чем третье.

Алгоритм метода заключается в нахождении частот N-грамм для всех тестовых документов, для которых известен язык, а также для каждого документа, язык которого пытаемся определить. После этого среди всех тестовых документов находим тот, для которого расстояние от его N-граммной статистики до статистики тестируемого документа минимально. После этого языком тестируемого документа считается язык найденного тестового документа.

Расстояние между статистиками подсчитывается следующим образом: все N-граммы сортируются в порядке убывания частоты их появления, затем для каждой N-граммы вычисляется разница её позиций в отсортированном списке N-грамм тестового и тестируемого документов. Расстояние между статистиками определяется как сумма разниц позиций каждой N-граммы. Если N-грамма (например, “ED” на рис.1) отсутствует в профиле категории (языка) то ей назначается максимальная величина оценки несовпадения позиций N-грамм.

Значение N предлагается использовать равным 5.

. Calculating The Out-Of-Place Measure Between Two Profiles



Note: These profiles are for explanatory purposes only and do not reflect real N-gram frequency statistics.

Рисунок 1. - Определение метрики несовпадения позиций N-грамм (Out Of Place) в профиле категории (языка текста, слева) и профиля входного (анализируемого, справа) документов.

Метод частотных слов

Согласно методу частотных слов ПОЯ представляет собой набор слов, обладающих наибольшей частотой встречаемости в сравнении с остальными словами документов из обучающего корпуса. Вероятность принадлежности входного документа языку определяется на основании пословного сравнения с ПОЯ с учётом рассчитанных вероятностей его элементов.

Метод коротких слов

Метод коротких слов при построении ПОЯ использует слова определённой длины, не превышающей заданный порог. Например, для каждого идентифицируемого языка, могут извлекаться лексемы длиной до пяти символов, встретившиеся в тексте более трёх раз. Вероятность появления в тексте i -й лексемы рассчитывалась как отношение её частоты к общей сумме частот всех лексем из полученного набора. Предложение входного документа разбивается на лексемы, и лексемам, присутствующим в ПОЯ, назначаются их частоты, а отсутствующим – некоторая минимальная частота. Вероятность принадлежности предложения языку рассчитывается как произведение вероятностей его лексем.

Порядок выполнения работы:

- построить тренировочный набор текстов для классифицируемых языков размером от 20 до 120 Кб;
- в соответствии с вариантом построить профили для классифицируемых языков на основании тренировочного набора текстов;
- в соответствии с вариантом построить профиль для каждого входного документа
- рассчитать метрику расстояния между профилем входного документа и каждым профилем классифицируемого языка;
- выбрать категорию с минимальным значением метрики и принять ее за результат.

Т.е. имеют место следующие основные шаги:

Шаг 1. предварительная обработка входного текста.

Шаг 2. распознавание языка представления текста.

- Сравнительный анализ профилей модели и входного документа.

Шаг 3. выбор ЕЯ для модели текста.

- Выбор ЕЯ с наименьшим значением метрики в качестве языка представления входного текста. Представление результатов.
- сравнить результаты распознавания различными методами.

Требования к разрабатываемой системе

- ✓ на входе – текстовые документы одинакового размера (например, 1 страница формата А4), содержащие тексты на естественных языках согласно варианту;
- ✓ на выходе – активная ссылка на документ, и результат идентификации отдельного текста – язык текста; сводная статистика по всем текстам из тестовой коллекции.
- ✓ наличие средств сохранения в файл и распечатки полученной на выходе информации;
- ✓ интерфейс системы - доступный для пользователей любого уровня, содержащий help-средства работы с программой.

№ варианта	Язык текста	Формат документа	Реализуемый метод
1	Русский, Английский	Html	N-грамм, алфавитный, нейросетевой
2	Французский, Немецкий	Html	N-грамм, алфавитный, нейросетевой
3	Испанский, Итальянский	Html	N-грамм, алфавитный, нейросетевой
4	Русский, Немецкий	Html	N-грамм, алфавитный, нейросетевой
5	Русский, Итальянский	Html	N-грамм, алфавитный, нейросетевой
6	Французский, Итальянский	Html	N-грамм, алфавитный, нейросетевой
7	Французский, Английский	Html	N-грамм, алфавитный, нейросетевой
8	Испанский, Немецкий	Html	N-грамм, алфавитный, нейросетевой
9	Испанский, Английский	Html	N-грамм, алфавитный, нейросетевой

10	Русский, Английский	Pdf	Частотных, коротких слов, нейросетевой
11	Французский, Немецкий	Pdf	Частотных, коротких слов, нейросетевой
12	Испанский, Итальянский	Pdf	Частотных, коротких слов, нейросетевой
13	Русский, Немецкий	Pdf	Частотных, коротких слов, нейросетевой
14	Русский, Итальянский	Pdf	Частотных, коротких слов, нейросетевой
15	Французский, Итальянский	Pdf	Частотных, коротких слов, нейросетевой
16	Французский, Английский	Pdf	Частотных, коротких слов, нейросетевой
17	Испанский, Немецкий	Pdf	Частотных, коротких слов, нейросетевой
18	Испанский, Английский	Pdf	Частотных, коротких слов, нейросетевой
19	Русский, Английский	Html	Частотных слов, алфавитный, нейросетевой
20	Французский, Немецкий	Html	Частотных слов, алфавитный, нейросетевой
21	Испанский, Итальянский	Html	Частотных слов, алфавитный, нейросетевой
22	Русский, Немецкий	Html	Частотных слов, алфавитный, нейросетевой
23	Русский, Итальянский	Html	Частотных слов, алфавитный, нейросетевой
24	Французский, Итальянский	Html	Частотных слов, алфавитный, нейросетевой
25	Французский, Английский	Html	Частотных слов, алфавитный, нейросетевой
26	Испанский, Немецкий	Html	Частотных слов, алфавитный, нейросетевой
27	Испанский, Английский	Html	Частотных слов, алфавитный, нейросетевой
28	Русский, Английский	Pdf	Коротких слов, алфавитный, нейросетевой
29	Французский, Немецкий	Pdf	Коротких слов, алфавитный, нейросетевой
30	Испанский, Итальянский	Pdf	Коротких слов, алфавитный, нейросетевой
31	Русский, Немецкий	Pdf	Коротких слов, алфавитный, нейросетевой
32	Русский, Итальянский	Pdf	Коротких слов, алфавитный, нейросетевой
33	Французский, Итальянский	Pdf	Коротких слов, алфавитный, нейросетевой
34	Французский, Английский	Pdf	Коротких слов, алфавитный, нейросетевой
35	Испанский, Немецкий	Pdf	Коротких слов, алфавитный,

			нейросетевой
36	Испанский, Английский	Pdf	Коротких слов, алфавитный, нейросетевой

В отчет по работе необходимо включить:

- ✓ информацию о тестовой коллекции документов (может быть сформирована на основании многоязычных текстов из Wikipedia);
- ✓ описание структуры разработанной системы;
- ✓ описание структур данных, использованных для хранения входной и выходной информации;
- ✓ описание алгоритма определения языка (в текстовом и графическом виде);
- ✓ результаты тестирования системы;
- ✓ оценку полученных результатов для пары методов быстрого действия системы (оценка точности и затраченного времени);
- ✓ описание и особенности применения готовых к использованию компонент (библиотек, классов, фреймворков и т.п.) в случае их использования в работе;
- ✓ выводы по работе и перспективам применения разработанной системы.