

# Лабораторная работа

## «Автоматическое реферирование документов»

**Цель работы** – освоить на практике основные принципы автоматического реферирования документов с учетом функционала, предоставляемого технологией OSTIS.

### Весовые коэффициенты значимости терминов

Функция автоматического реферирования – дать сжатое представление текстовой информации, позволяющее пользователю экономить время при поиске и отборе необходимой информации, т.е. «отсеивать» менее значимую информацию.

Можно выделить следующие типы рефератов:

- реферат в виде списка ключевых слов
- классический реферат
- структурированный реферат
- запросно-ориентированный реферат

**Реферат в виде ключевых слов** представляет собой список, возможно иерархический (в виде дерева) наиболее информативных слов и словосочетаний (именных групп) обрабатываемого документа. Такой реферат позволяет пользователю понять основные темы описанные в документе. Например: *лазер, лазерный луч, синий лазер, красный лазер, устройство* и т.д. Или в иерархическом виде:

*лазер*  
*лазерный луч*  
*синий лазер*  
*красный лазер*  
*устройство*  
и т.д.

**Классический реферат** – это набор наиболее информативных предложений текста, возможно трансформированных (удаление вводных конструкций, замена анафоричных местоимений и т.д. с целью улучшения связности реферата и уменьшения его объема).

При построении классического реферата методом sentence extraction необходимо:

1. Вычислить веса слов документа.

При этом слова из латинских букв, числа, стоп-слова - не учитываются. Базовый вес слова вычисляется по формуле  $TF \cdot IDF$ .

2. Вычислить веса предложений согласно формулам, приведенным ниже.

3. Осуществить генерацию реферата.

Этап генерации представляет собой выбор из исходного текста определенного количества предложений с наибольшим весом в той последовательности, в которой они идут в тексте. Рекомендуемый размер реферата 10 предложений.

Вес каждого предложения  $S_i$  вычисляется произведением значений функций приведенных ниже.

Функции, характеризующие положение предложения в документе  $Posd(S_i)$  и положение в абзаце  $Posp(S_i)$ :

$$\text{Posd}(S_i) = 1 - \frac{BD(S_i)}{|D|}$$

$$\text{Posp}(S_i) = 1 - \frac{BP(S_i)}{|P|}.$$

где

$|D|$  - число символов в документе D, содержащем предложение  $S_i$ ;

$BD(S_i)$  – количество символов до  $S_i$  в D( $S_i$ );

$|P|$  - количество символов в абзаце P, содержащем предложение  $S_i$ ;

$BP(S_i)$  – количество символов до  $S_i$  в абзаце.

Модифицированная TFIDF функция:

$$\text{Score}(S_i) = \sum_{t \in S_i} tf(t, S_i) \cdot w(t, D).$$

$tf(t, S_i)$  - частота термина t в предложении  $S_i$ ;

$$w(t, D) = 0.5 \left( 1 + \frac{tf(t, D)}{tf_{max}(D)} \right) \cdot \log \left( \frac{|DB|}{df(t)} \right).$$

$tf(t, D)$  - частота термина t в документе D;

$df(t)$  - количество документов, с термином t;

$tf_{max}(D)$  - максимальная частота термина в документе D;

$|DB|$  - количество документов.

### Требования к разрабатываемой системе

- ✓ на входе – на входе – текстовые документы одинакового размера (например, 10 страниц формата A4), содержащие тексты из предметных областей на естественных языках согласно варианту подлежащие процедуре автоматического реферирования;
- ✓ на выходе – активная ссылка на исходный документ и построенный реферат документа, состоящий из 2-х разделов:
  - классического реферата;
  - реферата в виде списка ключевых слов;
- ✓ наличие средств сохранения в файл и распечатки полученной на выходе информации;
- ✓ интерфейс системы должен быть предельно простым и доступным для пользователей любого уровня, содержать понятный набор инструментов и средств, а также help-средства.

| <b>№<br/>варианта</b> | <b>Язык текста</b>          | <b>Методика</b>               | <b>Предметная область</b>                                                      |
|-----------------------|-----------------------------|-------------------------------|--------------------------------------------------------------------------------|
| 1                     | Русский,<br>Английский      | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 2                     | Французский,<br>Немецкий    | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 3                     | Испанский,<br>Итальянский   | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 4                     | Русский,<br>Немецкий        | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 5                     | Русский,<br>Итальянский     | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 6                     | Французский,<br>Итальянский | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 7                     | Французский,<br>Английский  | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 8                     | Испанский,<br>Немецкий      | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 9                     | Испанский,<br>Английский    | Sentence extraction+<br>OSTIS | Научные статьи по computer science,<br>Сочинения по литературе                 |
| 10                    | Русский,<br>Английский      | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 11                    | Французский,<br>Немецкий    | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 12                    | Испанский,<br>Итальянский   | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 13                    | Русский,<br>Немецкий        | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 14                    | Русский,<br>Итальянский     | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 15                    | Французский,<br>Итальянский | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 16                    | Французский,<br>Английский  | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 17                    | Испанский,<br>Немецкий      | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 18                    | Испанский,<br>Английский    | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 19                    | Русский,<br>Английский      | Sentence extraction+<br>OSTIS | Научные статьи по медицине,<br>Критика предметов<br>изобразительного искусства |
| 20                    | Французский,<br>Немецкий    | Sentence extraction+<br>OSTIS | Научные статьи по медицине,                                                    |

|    |                          |                            |                                                                          |
|----|--------------------------|----------------------------|--------------------------------------------------------------------------|
|    |                          | OSTIS                      | Критика предметов изобразительного искусства                             |
| 21 | Испанский, Итальянский   | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 22 | Русский, Немецкий        | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 23 | Русский, Итальянский     | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 24 | Французский, Итальянский | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 25 | Французский, Английский  | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 26 | Испанский, Немецкий      | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |
| 27 | Испанский, Английский    | Sentence extraction+ OSTIS | Научные статьи по медицине, Критика предметов изобразительного искусства |

**В отчет по работе необходимо включить:**

- ✓ информацию о тестовой коллекции документов (может быть сформирована на основании многоязычных текстов из Wikipedia, Medline, других тематических ресурсов);
- ✓ описание структуры разработанной системы;
- ✓ описание структур данных, использованных для хранения входной и выходной информации;
- ✓ описание алгоритма построения реферата (в текстовом и графическом виде);
- ✓ результаты тестирования системы;
- ✓ оценку полученных результатов (оценка точности и затраченного времени т.д. для текстов разных предметных областей и естественных языков);
- ✓ описание и особенности применения готовых к использованию компонент (библиотек, классов, фреймворков и т.п.) в случае их использования в работе;
- ✓ выводы по работе и перспективам применения разработанной системы.